CÁC CHỦ ĐỀ ĐỒ ÁN CUỐI KỲ

1. Hệ thống Phân tích Dữ liệu Lớn với PySpark

- Thu thập dữ liệu từ nhiều nguồn như CSV, log files hoặc database.
- Thực hiện làm sạch dữ liệu, biến đổi dữ liệu và phân tích dữ liệu khám phá (EDA) bằng PySpark DataFrame.
- Áp dụng các phép aggregation, filtering và join trên dữ liệu lớn.
- Trực quan hóa kết quả phân tích để rút ra các insight từ dữ liệu.

---

2. Xây dựng Mô hình Học Máy trên Dữ liệu Lớn với PySpark MLlib

- Tiền xử lý dữ liệu và xây dựng pipeline học máy bằng PySpark MLlib.
- Áp dụng nhiều thuật toán như Logistic Regression, Random Forest, Gradient Boosting hoặc Decision Tree.
- So sánh hiệu suất các mô hình và đánh giá bằng accuracy, precision, recall, F1-score.
- Thực hiện tối ưu tham số (hyperparameter tuning) để cải thiện hiệu quả mô hình.

---

3. Xây dựng Hệ thống Gợi ý Quy mô Lớn

- Sử dụng dataset đánh giá sản phẩm hoặc phim (ví dụ MovieLens hoặc Amazon Reviews).
- Xây dựng hệ thống gợi ý dựa trên Collaborative Filtering với ALS trong PySpark.
- Thực hiện huấn luyện mô hình trên dữ liệu lớn và đánh giá hiệu quả gợi ý.
- Phân tích khả năng mở rộng của hệ thống khi dữ liệu tăng.

---

4. Phân tích Dữ liệu Thời gian Thực với PySpark Streaming

- Xây dựng hệ thống xử lý dữ liệu real-time bằng PySpark Structured Streaming.
- Thu thập dữ liệu từ nguồn streaming như log stream, socket hoặc Kafka.
- Thực hiện các phân tích như tính toán thống kê theo thời gian hoặc phát hiện sự kiện bất thường.
- So sánh xử lý dữ liệu batch vs streaming.

---

5. Phân tích Mạng Xã hội và Văn bản trên Dữ liệu Lớn

- Thu thập dữ liệu từ social network hoặc text dataset (tweets, reviews).
- Thực hiện xử lý ngôn ngữ tự nhiên (NLP) bằng PySpark: tokenization, stopword removal, TF-IDF.
- Xây dựng đồ thị tương tác người dùng và phân tích social network graph.
- Kết hợp phân tích văn bản và phân tích mạng để rút ra insight.

6. Tự chọn tương tương